

RANGKUMAN MATERI

BUSINESS INTELLIGENCE

Disusun oleh:

Aden Sahwaludin (NPM 5220311117)

Program Studi Sistem Informasi – Fakultas Sains & Teknologi
Universitas Teknologi Yogyakarta – 2025

1. Pengenalan dan Dasar Business Intelligence

Business Intelligence (BI) adalah sekumpulan konsep, metodologi, dan teknologi yang digunakan untuk mengubah data mentah menjadi informasi bermakna guna mendukung pengambilan keputusan yang lebih baik (Ragazou *et al.*, 2023 ¹). BI menggabungkan berbagai *tools*, infrastruktur, dan proses untuk mengumpulkan, menyimpan, mengolah, serta menganalisis data bisnis, sehingga manajer dapat membuat keputusan secara *fact-based* alih-alih hanya mengandalkan intuisi. Komponen inti BI mencakup sumber data (misalnya database operasional, ERP, log web, media sosial), proses ETL (*extract, transform, load*) untuk integrasi data, penyimpanan terpusat seperti *data warehouse* atau *data lake*, dan perangkat analitik serta visualisasi untuk penyajian informasi. Dengan kerangka kerja ini, BI memungkinkan penerapan berbagai jenis analisis data, mulai dari analisis deskriptif untuk memahami apa yang telah terjadi, analisis diagnostik untuk mengetahui mengapa hal itu terjadi, hingga analisis prediktif untuk memproyeksikan tren masa depan (Sharda *et al.*, 2020; Delen & Ram, 2018 ² ³). Melalui BI, organisasi dapat memantau kinerja secara menyeluruh, mengidentifikasi peluang bisnis baru, meningkatkan efisiensi operasional, dan memberikan layanan yang lebih baik kepada pelanggan. Bahkan bagi usaha kecil dan menengah, pemanfaatan BI membantu mempercepat dan meningkatkan akurasi pengambilan keputusan sehingga memperkuat daya saing mereka ⁴. Meski menawarkan banyak manfaat, implementasi BI dihadapkan pada sejumlah tantangan. Kualitas data yang rendah (misalnya data tidak lengkap atau tidak konsisten) sering menjadi kendala utama, di samping keterbatasan sumber daya manusia yang memiliki keahlian analitik, serta kurangnya dukungan manajemen puncak untuk inisiatif berbasis data. Keberhasilan penerapan BI sangat bergantung pada kesiapan organisasi secara keseluruhan, termasuk tata kelola data yang baik dan budaya kerja yang mendukung penggunaan data dalam setiap keputusan (Hmoud *et al.*, 2023; Matias & Piedade, 2024 ⁵ ⁶). Secara keseluruhan, BI telah menjadi fondasi penting dalam manajemen modern karena kemampuannya menyediakan informasi yang relevan, akurat, dan tepat waktu bagi pengambil keputusan. Dengan implementasi yang tepat, BI tidak hanya membantu keputusan operasional sehari-hari, tetapi juga berperan sebagai instrumen strategis untuk mencapai tujuan jangka panjang organisasi (Gürçan *et al.*, 2023 ⁷).

2. Deskripsi dan Pengumpulan Data (*Data Mining*)

Dalam konteks BI, tahap deskripsi dan pengumpulan data merupakan langkah awal yang sangat krusial sebelum melakukan analisis lebih lanjut. Pengumpulan data dilakukan dari berbagai sumber, baik internal

(misalnya sistem transaksi perusahaan, sistem ERP) maupun eksternal (seperti media sosial, sensor *Internet of Things*, hingga *open data* publik). Kualitas dan kelengkapan data yang berhasil dikumpulkan akan sangat menentukan kualitas *insight* yang dihasilkan oleh sistem BI (Chen *et al.*, 2021 ⁸). Selanjutnya, proses deskripsi data bertujuan untuk memahami karakteristik dasar dari data yang diperoleh. Statistik deskriptif sederhana – seperti rata-rata, median, standar deviasi, distribusi frekuensi – digunakan untuk memberikan gambaran umum mengenai data tersebut. Dengan langkah ini, analisis BI dapat mengenali pola awal, anomali, atau inkonsistensi dalam data, yang perlu ditangani pada tahap berikutnya (Delen & Ram, 2018; Sharda *et al.*, 2020 ⁹ ¹⁰). Setelah data terkumpul dan dideskripsikan, tahap inti berikutnya adalah *data mining*. *Data mining* didefinisikan sebagai proses mengekstraksi informasi bermakna, pola tersembunyi, dan hubungan penting dari kumpulan data yang besar dan kompleks. Teknik-teknik seperti klasifikasi, klusterisasi, asosiasi (*association rules*), dan regresi banyak digunakan dalam *data mining* untuk mendukung pengambilan keputusan berbasis data (Kotu & Deshpande, 2020 ¹¹). Dalam BI, penerapan teknik-teknik ini membantu organisasi mengidentifikasi tren bisnis, memprediksi permintaan pasar, serta memahami perilaku pelanggan secara lebih mendalam (Kotu & Deshpande, 2020; Shmueli *et al.*, 2020 ¹²). Perkembangan teknologi *big data* dan *machine learning* di dekade terakhir turut memengaruhi proses pengumpulan data. Volume dan kecepatan data yang meningkat menuntut perusahaan untuk mampu melakukan pengumpulan dan pemrosesan data secara *real-time*. Dengan memanfaatkan integrasi data waktu nyata, perusahaan dapat memasukkan data operasional langsung ke dalam sistem BI, sehingga keputusan dapat diambil dengan lebih cepat dan responsif terhadap perubahan pasar (Mikalef *et al.*, 2020 ¹³). Tentu saja, tahap pengumpulan dan deskripsi data ini juga memiliki tantangan tersendiri. Sering kali data mentah yang diperoleh tidak sepenuhnya siap pakai: terdapat nilai-nilai hilang, duplikasi, kesalahan pencatatan, ataupun *bias*. Oleh sebab itu, diperlukan proses *data preprocessing* seperti pembersihan data, normalisasi, dan integrasi pada tahap selanjutnya agar hasil analisis BI dapat diandalkan (Aljawarneh *et al.*, 2022 ¹⁴ ¹⁵).

3. Pre-processing dan Visualisasi Data

Tahap *data pre-processing* merupakan bagian penting dalam siklus BI karena kualitas data sangat menentukan akurasi hasil analisis. Data mentah yang dikumpulkan dari berbagai sumber sering kali mengandung masalah kualitas, misalnya tidak lengkap, terdapat duplikasi, atau formatnya beragam. Oleh karena itu, proses *pre-processing* mencakup serangkaian langkah untuk membersihkan dan mempersiapkan data sebelum dianalisis lebih lanjut. Langkah-langkah utama *pre-processing* antara lain pembersihan data (*data cleaning*), integrasi, transformasi, normalisasi, hingga reduksi dimensi. Pembersihan data dilakukan untuk menangani *missing values* atau data yang tidak valid, sehingga anomali atau kesalahan dapat diminimalkan. Kemudian, integrasi data dibutuhkan agar data dari berbagai sumber dapat digabungkan ke dalam satu repositori terpadu dengan konsisten. Selanjutnya, transformasi dan normalisasi data bertujuan menyamakan skala atau format data (misalnya mengubah semua tanggal ke format yang sama, atau menormalisasi rentang nilai numerik) sehingga berbagai atribut dapat dibandingkan secara *apple-to-apple*. Pada kasus data yang sangat besar atau berdimensi tinggi, teknik reduksi dimensi dapat diterapkan untuk mengurangi jumlah atribut dengan memfilter informasi yang paling relevan, tanpa membuang esensi pentingnya. Upaya reduksi ini akan menyederhanakan struktur data, meningkatkan efisiensi komputasi, serta membantu mencegah *overfitting* pada model analitik (Al-Hadhrani *et al.*, 2021). Hasil akhirnya, *pre-processing* menghasilkan dataset yang lebih bersih, konsisten, dan siap digunakan untuk tahap analisis lanjutan ¹⁶ ¹⁷.

Setelah data melalui tahap *pre-processing*, langkah berikutnya dalam BI adalah visualisasi data. *Data visualization* merupakan proses penyajian informasi dalam bentuk grafis, seperti diagram, grafik, peta

panas (*heatmap*), dan *dashboard* interaktif. Dalam BI, visualisasi memegang peran vital karena membantu pengambil keputusan memahami pola, tren, dan hubungan dalam data secara lebih cepat dan intuitif (Cai & Zhu, 2022). Sebagai contoh, *dashboard* interaktif memungkinkan manajemen memantau *Key Performance Indicators* (KPI) secara waktu nyata melalui tampilan visual yang mudah dibaca. Dengan visualisasi, data yang kompleks dapat disarikan menjadi bentuk yang lebih sederhana sehingga memudahkan identifikasi informasi penting sekilas pandang. Hal ini tentu mempercepat proses pengambilan keputusan strategis, karena eksekutif dapat segera melihat area-area yang memerlukan perhatian atau intervensi. Selain itu, visualisasi yang efektif juga mendukung komunikasi lintas departemen: temuan analisis dapat dipresentasikan dalam format visual yang jelas dan menarik, sehingga lebih mudah dipahami oleh audiens non-teknis (Aljawarneh *et al.*, 2022 ¹⁸ ¹⁹). Meskipun demikian, tantangan utama dalam visualisasi data adalah bagaimana menyajikan informasi secara tepat sasaran. Visualisasi harus tidak hanya menarik secara estetika, tetapi juga relevan dan mudah diinterpretasikan. Pemilihan jenis grafik atau chart yang sesuai untuk suatu jenis data menjadi penting agar pesan yang terkandung tidak disalahartikan. Selain itu, seiring perkembangan teknologi, integrasi visualisasi dengan analitik modern (misalnya *real-time analytics* dan *streaming data*) menjadi faktor kunci penentu efektivitas BI (Mikalef *et al.*, 2020 ²⁰ ¹⁵). Organisasi perlu memastikan bahwa visualisasi yang digunakan mampu menangani volume dan kecepatan data yang kian meningkat, serta dapat diperbarui secara dinamis. Dengan menghadapi tantangan-tantangan tersebut, visualisasi data yang baik akan semakin memberdayakan pengguna dalam menggali wawasan bisnis dan mengambil keputusan secara cepat dan tepat.

4. Natural Language Processing (NLP)

Natural Language Processing (NLP) adalah cabang dari kecerdasan buatan yang berfokus pada memungkinkan komputer untuk memahami, mengolah, dan menghasilkan bahasa manusia secara alami. Dalam konteks BI, NLP menjadi sangat penting mengingat semakin banyaknya data tekstual yang tersedia dan relevan bagi bisnis, seperti ulasan pelanggan, posting media sosial, *chat logs*, email, hingga dokumen laporan. NLP menyediakan mekanisme bagi perusahaan untuk mengekstraksi wawasan berharga dari data teks yang tidak terstruktur, sesuatu yang sulit dilakukan dengan analisis data tradisional berbasis angka (Cambria *et al.*, 2022 ²¹ ²²). Contoh penerapan utama NLP dalam BI adalah *text mining* dan analisis topik dari dokumen-dokumen bisnis, yang memungkinkan organisasi menemukan pola tersembunyi, kata kunci populer, atau topik yang sering dibicarakan, tanpa harus membaca secara manual ribuan dokumen (Manning & Jurafsky, 2020 ²³ ²⁴). Selain itu, NLP juga menjadi fondasi bagi *chatbot* atau asisten virtual cerdas yang terintegrasi dengan sistem BI. Teknologi ini memungkinkan pengguna bisnis – termasuk yang non-teknis – untuk berinteraksi dengan sistem BI menggunakan bahasa alami. Sebagai ilustrasi, seorang manajer dapat langsung bertanya kepada sistem BI dengan kalimat sehari-hari, misalnya, “Berapa total penjualan produk X bulan lalu?”, dan sistem akan memahami pertanyaan tersebut lalu memberikan jawaban berupa angka penjualan berdasarkan data internal perusahaan (Kaur & Kautish, 2021 ²⁵ ²⁶). Kemampuan ini menurunkan hambatan bagi pengambil keputusan dalam memanfaatkan BI, karena mereka tidak perlu menguasai bahasa pemrograman atau *query* teknis untuk mendapatkan informasi yang dibutuhkan. Secara keseluruhan, NLP memberikan nilai tambah signifikan dalam dunia BI karena dapat mengolah informasi berbasis teks – yang sebelumnya sulit dianalisis – menjadi *insight* yang dapat ditindaklanjuti. Hal ini menjadikan NLP salah satu pilar utama dalam transformasi digital dan pengambilan keputusan berbasis data di era modern, di mana data tekstual dari pelanggan dan stakeholder lainnya terus bertumbuh secara eksponensial. Dengan memanfaatkan NLP, perusahaan dapat mendengar “suara” pelanggan dan pasar melalui data teks, lalu merespons dengan keputusan bisnis yang lebih tepat dan proaktif.

5. Analisis Sentimen (*Opinion Mining*)

Analisis sentimen, atau dikenal pula sebagai *opinion mining*, merupakan teknik dalam NLP yang bertujuan untuk mengidentifikasi dan mengekstraksi opini, emosi, atau sentimen dari teks. Dalam konteks BI, analisis sentimen menjadi sangat penting karena memungkinkan organisasi memahami persepsi dan sikap pelanggan terhadap produk, layanan, atau merek mereka secara luas dan mendalam. Sumber data yang umum digunakan untuk analisis sentimen antara lain ulasan produk di e-commerce, cuitan di Twitter, komentar di media sosial, forum diskusi, hingga survei pelanggan (Cambria *et al.*, 2022²⁷²⁸). Dengan memanfaatkan teknik ini, perusahaan dapat memantau sentimen publik secara *real-time*, mendeteksi tren opini yang berkembang, serta mengidentifikasi potensi masalah lebih dini. Sebagai contoh, lonjakan komentar negatif tentang suatu produk di media sosial dapat menjadi sinyal peringatan bagi perusahaan untuk segera mengevaluasi dan memperbaiki kualitas produk atau layanan tersebut sebelum isu itu meluas dan merusak reputasi (Liu, 2020²⁹³⁰). Selain reaktif terhadap isu, hasil analisis sentimen juga dapat dijadikan masukan berharga dalam perencanaan strategis. Informasi tentang aspek apa saja yang disukai atau dikeluhkan pelanggan dapat digunakan untuk pengembangan produk baru maupun penyempurnaan layanan. Dalam ranah pemasaran, analisis sentimen membantu tim pemasaran menilai efektivitas kampanye (apakah mendapat sentimen positif atau negatif dari audiens) dan memahami preferensi pelanggan secara emosional, sehingga kampanye di masa mendatang dapat lebih tepat sasaran. Bahkan, hasil analisis sentimen kini mulai diintegrasikan dengan sistem rekomendasi dan model prediksi. Misalnya, rating atau sentimen positif terhadap produk tertentu dapat meningkatkan kecenderungan sistem untuk merekomendasikan produk serupa kepada calon pembeli lain. Sebaliknya, sentimen negatif bisa menjadi *warning* untuk mengurangi promosi produk terkait. Integrasi *opinion mining* ke dalam BI menjadikan analisis data lebih komprehensif karena menggabungkan data kuantitatif (angka penjualan, demografi, dll.) dengan data kualitatif (opini dan komentar teks) untuk mendukung keputusan strategis (Kaur & Kautish, 2021³¹³²). Tantangan dalam analisis sentimen antara lain adalah kemampuan model untuk memahami konteks bahasa, ironi, atau sarkasme, yang dapat memengaruhi akurasi pendeteksian emosi. Meski begitu, kemajuan di bidang AI – seperti pemanfaatan *deep learning* dan sumber pengetahuan umum (contoh: *SenticNet 7*) – terus meningkatkan akurasi dan *explainability* dalam analisis sentimen (Cambria *et al.*, 2022). Secara keseluruhan, analisis sentimen membantu organisasi semakin *customer-centric* dengan mendengarkan *voice of customer* secara luas dan *real-time*, lalu menggunakan wawasan tersebut untuk meningkatkan kepuasan pelanggan dan keunggulan bisnis.

6. Analisis Deskriptif

Analisis deskriptif adalah pendekatan analisis data yang berfokus pada menggambarkan atau merangkum informasi mengenai apa yang telah terjadi di masa lalu. Dalam BI, analisis deskriptif digunakan untuk mengolah dan menyajikan data historis dalam bentuk yang mudah dipahami, seperti laporan, tabel ringkasan, grafik tren, atau *dashboard* ringkas. Tujuannya adalah memberikan pandangan menyeluruh kepada manajer tentang kondisi bisnis saat ini atau kinerja masa lampau, sebagai landasan pemahaman sebelum melangkah ke analisis lanjutan. Misalnya, laporan penjualan bulanan yang menunjukkan total penjualan per produk atau per wilayah adalah contoh analisis deskriptif – ia menjawab pertanyaan “*apa yang terjadi?*” secara informatif (Delen & Ram, 2018³³³⁴). Analisis deskriptif tidak mencoba memprediksi masa depan atau menjelaskan *mengapa* sesuatu terjadi; fokusnya murni pada *menggambarkan* data yang telah terkumpul dengan cara yang berguna. Dengan teknik ini, perusahaan dapat mengidentifikasi tren historis, pola musiman, atau variabilitas dalam data. Sebagai contoh, perusahaan ritel dapat menggunakan analisis deskriptif untuk melihat tren penjualan per kategori produk selama beberapa tahun terakhir, atau perbandingan kinerja cabang toko per kuartal, sehingga area yang berkinerja tinggi maupun yang perlu

perhatian dapat terlihat jelas (Sharda *et al.*, 2020³⁵³⁶). Analisis deskriptif sering diwujudkan dalam BI melalui *dashboard* monitoring dan laporan periodik (harian, mingguan, bulanan). *Dashboard* BI biasanya mengkompilasi berbagai metrik kinerja kunci (Key Performance Indicators) secara visual sehingga manajemen mendapatkan *snapshot* cepat bisnis mereka. Meskipun analisis deskriptif dianggap paling sederhana dibanding jenis analisis lainnya, perannya sangat fundamental. Ia menyediakan *baseline* informasi yang diperlukan sebelum beralih ke analisis diagnostik (mengapa hal itu terjadi), prediktif (apa yang mungkin terjadi), maupun preskriptif (apa yang seharusnya dilakukan). Dengan kata lain, analisis deskriptif membantu memastikan bahwa pengambil keputusan memahami *konteks* dan *fakta* saat ini dengan benar sebelum mengambil langkah lebih lanjut. Bahkan, output analisis deskriptif sering menjadi input bagi model prediktif atau algoritma lainnya. Contohnya, pola tren penjualan historis (hasil analisis deskriptif) mungkin digunakan sebagai salah satu variabel dalam model prediksi permintaan. Dalam BI modern, analisis deskriptif juga makin efektif berkat integrasi dengan visualisasi data. Grafik dan chart interaktif memperkuat kemampuan deskriptif dengan memfasilitasi eksplorasi data lebih lanjut oleh pengguna (misal, *drill-down* untuk melihat rincian). Singkatnya, analisis deskriptif berfungsi sebagai fondasi utama yang membantu organisasi mengubah data mentah menjadi informasi yang mudah dipahami dan bernilai untuk pengambilan keputusan (Chen *et al.*, 2021³⁷³⁸). Tanpa pemahaman deskriptif yang kuat, upaya analisis lanjutan dapat kehilangan arah atau konteks. Oleh karenanya, meski *insight* yang dihasilkan bersifat *retrospective* (berdasarkan masa lalu), analisis deskriptif tetap merupakan komponen tak terpisahkan dari BI yang sukses.

7. Sistem Rekomendasi

Sistem rekomendasi adalah komponen penting BI yang berfungsi memberikan saran atau prediksi bersifat personal kepada pengguna berdasarkan pola preferensi atau perilaku mereka. Dalam dunia bisnis modern, sistem rekomendasi sangat luas penerapannya, terutama pada industri dengan interaksi konsumen langsung yang intens. Contohnya meliputi platform e-commerce (merekomendasikan produk yang mungkin disukai pelanggan), layanan streaming musik/film (menawarkan lagu atau film sesuai selera pengguna), hingga sektor perbankan digital (memberikan rekomendasi produk keuangan sesuai profil nasabah). Tujuan utama sistem rekomendasi adalah meningkatkan pengalaman pengguna dengan menyajikan opsi yang paling relevan, sekaligus mendorong *engagement* dan penjualan perusahaan³⁹⁴⁰. Secara umum, terdapat beberapa pendekatan algoritmik yang digunakan dalam sistem rekomendasi: *collaborative filtering*, *content-based filtering*, dan pendekatan hibrida. *Collaborative filtering* memanfaatkan kemiripan pola di antara banyak pengguna – misalnya, jika banyak orang dengan selera mirip si A menyukai produk X, maka produk X direkomendasikan juga untuk A. *Content-based filtering* berfokus pada kesamaan karakteristik konten – merekomendasikan item yang mirip dengan yang disukai pengguna di masa lalu. Sementara pendekatan *hybrid* menggabungkan keduanya untuk mendapatkan keunggulan masing-masing (Jannach *et al.*, 2021; Ricci *et al.*, 2022⁴¹⁴²). Dalam BI, integrasi sistem rekomendasi memungkinkan perusahaan bukan hanya menganalisis data historis, tetapi juga langsung memberikan *actionable insight* berupa rekomendasi kepada pengguna atau pelanggan. Sebagai contoh, analisis BI dapat mengungkap pola belanja pelanggan – katakanlah pelanggan cenderung membeli item A dan B bersamaan – lalu sistem rekomendasi menggunakan informasi tersebut untuk menyarankan item B kepada pelanggan yang membeli item A, yang akhirnya meningkatkan *cross-selling* dan kepuasan pelanggan. Penerapan seperti ini terbukti dapat meningkatkan loyalitas pelanggan dan juga pendapatan perusahaan (Zhou *et al.*, 2020⁴³⁴⁴). Selain untuk pelanggan, sistem rekomendasi juga bermanfaat bagi pengambil keputusan internal; misalnya merekomendasikan aksi atau strategi terbaik berdasarkan data kinerja (meskipun kasus ini lebih jarang dan biasanya masuk ranah *prescriptive analytics*). Tantangan dalam penerapan sistem rekomendasi meliputi masalah *cold start* (bagaimana memberikan rekomendasi untuk pengguna/item baru

yang datanya minim), bias dalam data (misal kecenderungan algoritma hanya merekomendasikan item populer dan mengabaikan *niche*), serta kebutuhan akan interpretabilitas rekomendasi (dalam beberapa kasus bisnis, penting menjelaskan mengapa sebuah item direkomendasikan). Penelitian terbaru telah mengeksplorasi berbagai metode untuk mengatasi tantangan-tantangan tersebut, misalnya dengan *deep learning* yang mampu menangkap pola kompleks atau teknik *explainable recommendations* (Zhang *et al.*, 2019). Secara strategis, sistem rekomendasi dalam BI bukan hanya alat bantu keputusan taktis, tetapi juga sarana untuk meningkatkan daya saing bisnis di era digital. Dengan memanfaatkan *big data* dan algoritma pembelajaran mesin yang kian canggih, rekomendasi yang dihasilkan dapat sangat personal dan *real-time*, sehingga perusahaan dapat memberikan pengalaman unik bagi setiap pelanggan. Hal ini berkontribusi pada peningkatan retensi pelanggan, nilai transaksi, dan pada akhirnya transformasi digital bisnis secara menyeluruh (Zhang *et al.*, 2019 ⁴⁵ ⁴⁶).

8. Sistem Prediksi

Sistem prediksi adalah komponen BI yang digunakan untuk memperkirakan kejadian atau tren di masa depan berdasarkan pola dan informasi dari data historis. Sistem ini pada dasarnya menjawab pertanyaan “apa yang kemungkinan terjadi selanjutnya?” dan berusaha memberikan *head start* bagi organisasi untuk menyusun rencana proaktif. Dalam implementasinya, sistem prediksi memanfaatkan berbagai teknik seperti *machine learning*, *data mining*, hingga pemodelan statistik klasik. Berbagai algoritma – mulai dari regresi linier sederhana, *time series forecasting*, *decision tree*, *random forest*, hingga *neural networks* – dapat digunakan tergantung pada jenis masalah prediksi yang dihadapi. Keluaran dari sistem prediksi bisa beragam, misalnya prediksi nilai numerik (seperti jumlah penjualan bulan depan), klasifikasi kategori (apakah pelanggan X berisiko *churn* atau tidak), atau deteksi anomali (memprediksi adanya transaksi penipuan) ⁴⁷ ⁴⁸ . Dalam konteks bisnis, sistem prediksi membantu organisasi mengantisipasi kebutuhan dan mengambil tindakan sebelum suatu peristiwa terjadi. Sebagai contoh, melalui analisis data historis penjualan, sebuah perusahaan ritel dapat memprediksi produk apa yang akan mengalami lonjakan permintaan di musim liburan mendatang. Informasi ini memungkinkan perusahaan tersebut menyiapkan stok dan rantai pasok lebih dini, sehingga terhindar dari kekurangan barang yang dapat mengecewakan pelanggan (Waller & Fawcett, 2019 ⁴⁹ ⁵⁰). Contoh lain, di sektor perbankan, model prediksi banyak digunakan untuk menilai risiko kredit – apakah seorang pemohon pinjaman berpotensi gagal bayar – maupun mendeteksi *fraud* (penipuan) secara dini dengan mengidentifikasi pola transaksi mencurigakan. Dalam investasi dan pasar saham, sistem prediksi digunakan untuk memproyeksikan pergerakan harga atau indikator ekonomi, meskipun tentu dengan ketidakpastian yang lebih tinggi. Integrasi sistem prediksi ke dalam lingkungan BI memungkinkan perusahaan beralih dari pendekatan reaktif ke proaktif. Keputusan bisnis dapat dibuat dengan pandangan ke depan, bukan sekadar berdasarkan kejadian lampau. Hal ini sangat bernilai di era persaingan ketat, karena perusahaan yang dapat bergerak lebih awal akan memiliki keunggulan. Studi menunjukkan bahwa penggabungan kemampuan prediktif dengan BI dapat mendorong organisasi mengambil keputusan yang lebih *proactive* dan *data-driven*, sehingga tidak tertinggal oleh perubahan pasar (Ahmed *et al.*, 2020 ⁵¹ ⁵²). Tentu, akurasi model prediksi sangat penting; karenanya perusahaan perlu terus memantau dan memvalidasi model dengan data terbaru serta melakukan penyempurnaan jika diperlukan. Tantangan seperti *overfitting*, perubahan pola (*concept drift*), atau ketidakpastian data harus dikelola agar prediksi tetap andal. Selain itu, interpretabilitas model juga menjadi perhatian, terutama untuk keputusan yang sensitif (contoh: model prediksi risiko kredit sebaiknya dapat dijelaskan alasannya demi kepatuhan dan *fairness*). Saat ini, kombinasi pemanfaatan *big data* dan algoritma prediktif yang semakin canggih menjadikan sistem prediksi sebagai kunci dalam meningkatkan daya saing organisasi. Dengan BI prediktif, perusahaan dapat menyusun strategi jangka panjang yang lebih

solid karena didukung perkiraan berbasis data, sekaligus memiliki kelincahan untuk menyesuaikan arah ketika sinyal perubahan di masa depan terdeteksi (Shmueli *et al.*, 2020; Kotu & Deshpande, 2019 ⁸ ¹¹).

9. Association Rule

Analisis association rule (aturan asosiasi) adalah teknik *data mining* yang bertujuan menemukan keterkaitan atau pola *if-then* antar item dalam satu *dataset*. Pola yang ditemukan biasanya berupa pernyataan seperti "*jika A terjadi, maka B cenderung terjadi*," lengkap dengan metrik pengukur kekuatan hubungan (misalnya *support*, *confidence*, dan *lift*). Aplikasi klasik dari *association rule mining* adalah *market basket analysis* dalam industri ritel: melalui analisis transaksi, perusahaan dapat menemukan kombinasi produk yang sering dibeli bersamaan oleh pelanggan. Sebagai contoh, analisis mungkin mengungkap aturan bahwa "*jika pelanggan membeli roti, maka 80% kemungkinan mereka juga membeli susu*". Wawasan semacam ini berharga bagi peritel untuk mengatur tata letak toko (misal menempatkan produk terkait berdekatan), membuat bundling promosi, atau strategi *cross-selling* lainnya ⁵³ ⁵⁴. Dalam konteks BI yang lebih luas, *association rules* membantu mengungkap hubungan tersembunyi antar variabel bisnis yang mungkin tidak terdeteksi oleh analisis biasa. Selain di ritel, teknik ini diterapkan di berbagai domain: bank dapat menganalisis keterkaitan penggunaan berbagai produk finansial oleh nasabah, perusahaan telekomunikasi dapat menemukan asosiasi antara fitur layanan yang digunakan pelanggan, atau analisis keranjang belanja e-commerce untuk personalisasi rekomendasi. Keunggulan *association rule mining* adalah sifatnya yang *unsupervised* – algoritma dapat menemukan pola tanpa perlu variabel target, sehingga sangat eksploratif dan mampu menghasilkan hipotesis bisnis baru. BI memanfaatkan hasil *association rules* ini sebagai *insight* untuk pengambilan keputusan, misalnya menentukan produk apa yang sebaiknya dipromosikan bersama, atau segmen pelanggan mana yang berpotensi untuk strategi penjualan tertentu (Shmueli *et al.*, 2020).

Manfaat analisis asosiasi dalam bisnis terlihat dari kemampuannya menyaring *big data* transaksi menjadi pengetahuan praktis. Informasi mengenai kombinasi item yang sering muncul bersamaan dapat membantu optimalisasi inventori (stok produk komplemen dikelola berbarengan), strategi katalog atau penempatan produk (item terkait ditampilkan bersamaan untuk mendorong pembelian impulsif), hingga rekomendasi otomatis di platform digital ("*Pelanggan yang membeli X juga membeli Y*"). Namun, teknik ini juga memiliki tantangan. Salah satunya adalah potensi dihasilkannya *rules* yang sangat banyak, terutama dari *dataset* besar, sehingga menyulitkan interpretasi. Dibutuhkan penetapan ambang *support* dan *confidence* yang tepat agar hanya aturan signifikan yang diambil, dan manajer tidak tenggelam dalam ratusan aturan yang tidak relevan. Tantangan lain adalah memastikan aturan yang ditemukan benar-benar bermakna dan bukan korelasi kebetulan. Oleh karena itu, tahap evaluasi dan validasi bisnis terhadap *rules* yang dihasilkan sangat penting – misalnya, aturan yang muncul harus ditinjau apakah masuk akal secara domain knowledge. Dalam beberapa kasus, visualisasi *association rules* (seperti *network graph* atau matriks hubungan) dapat membantu ahli bisnis memahami pola yang ditemukan dan memilih mana yang actionable ⁵⁵. Seiring berkembangnya data yang dianalisis (misalnya data sekuensial waktu atau data multidimensi), algoritma *association mining* juga berkembang untuk menangani kompleksitas lebih tinggi, seperti *sequential pattern mining* atau *high-dimensional association*. Secara keseluruhan, analisis *association rule* menyediakan cara efektif bagi organisasi untuk menggali pola keterkaitan di dalam data mereka, mendukung pengambilan keputusan seperti penawaran produk yang lebih tepat, peningkatan pengalaman pelanggan, dan efisiensi operasional. Dengan kata lain, teknik ini membantu mengubah *data transaksi* yang melimpah menjadi *pengetahuan bisnis* yang dapat ditindaklanjuti.

10. Clustering

Clustering (analisis pengelompokan) adalah teknik *unsupervised learning* yang bertujuan mengelompokkan sekumpulan objek (misalnya pelanggan, produk, atau entitas bisnis lainnya) ke dalam grup atau kluster sedemikian rupa sehingga objek dalam satu kluster memiliki kemiripan tinggi satu sama lain, dan berbeda secara signifikan dengan objek di kluster lain. Berbeda dari klasifikasi, clustering tidak memerlukan label atau kategori sebelumnya; algoritma secara otomatis menemukan struktur pengelompokan yang *natural* dari data. Dalam BI, clustering berperan besar dalam *segmentasi* – upaya memahami struktur heterogen dalam basis data perusahaan. Salah satu contoh paling umum adalah *customer segmentation*: perusahaan mengelompokkan pelanggan ke dalam beberapa segmen homogen berdasarkan pola perilaku atau karakteristik mereka. Segmen yang dihasilkan (misalnya “*kluster pelanggan muda urban yang gemar produk teknologi*” vs “*kluster pelanggan keluarga yang fokus pada harga*”) dapat menjadi landasan strategis untuk diferensiasi pelayanan, penargetan pemasaran, dan pengembangan produk (Sharda *et al.*, 2020). Dengan memahami setiap kluster pelanggan, perusahaan dapat merancang pendekatan yang lebih tepat sasaran untuk masing-masing segmen, alhasil meningkatkan kepuasan dan retensi pelanggan. Selain segmentasi pelanggan, clustering juga digunakan dalam berbagai konteks bisnis lain, seperti mengelompokkan cabang toko atau wilayah pasar dengan pola penjualan serupa (guna mempermudah analisis kinerja per region), mengelompokkan produk ke dalam kategori berdasarkan atribut penjualan (untuk *assortment planning*), atau mendeteksi anomali dengan mencari data poin yang tidak masuk ke kluster manapun (berguna dalam deteksi penipuan atau *outlier*).

Algoritma clustering yang paling populer dan sering diajarkan dalam BI adalah **k-means clustering**. Algoritma ini bekerja dengan menentukan *jumlah kluster K* terlebih dahulu, lalu secara iteratif mengelompokkan data ke kluster dengan meminimalkan jarak antara data dengan *centroid* kluster. K-means disukai karena relatif sederhana dan cepat untuk dataset berukuran besar, namun juga memiliki kelemahan seperti keharusan menentukan K di awal dan sensitivitas terhadap inisialisasi awal (Han *et al.*, 2022). Selain k-means, terdapat algoritma clustering lainnya seperti *hierarchical clustering* (yang menghasilkan dendrogram hirarki pengelompokan), DBSCAN (yang dapat membentuk kluster dengan bentuk arbitrer dan menangani *noise*), serta algoritma berbasis model probabilistik seperti Gaussian Mixture Models. Pemilihan algoritma bergantung pada karakteristik data dan tujuan analisis.

Penerapan clustering dalam BI memberikan sejumlah manfaat nyata. Pertama, ia membantu dalam penemuan pengetahuan yang mungkin tidak terduga sebelumnya. Contohnya, melalui clustering mungkin terungkap adanya segmen pelanggan baru yang sebelumnya luput dari perhatian, namun ternyata bernilai tinggi. Kedua, hasil clustering menyederhanakan kompleksitas data – ribuan data poin dapat direduksi menjadi beberapa kluster yang mewakili pola dominan, sehingga memudahkan komunikasi hasil analisis kepada manajemen. Ketiga, clustering sering menjadi input bagi analisis lanjutan; misal, model prediktif terpisah dapat dibangun untuk setiap kluster pelanggan demi meningkatkan akurasi (karena data lebih homogen dalam kluster tersebut).

Tantangan dalam analisis clustering juga patut dipertimbangkan. Menentukan jumlah kluster yang optimal (nilai K) bukan hal sepele; biasanya analisis perlu menggunakan metrik seperti *silhouette score* atau *elbow method* untuk membantunya, disertai pertimbangan bisnis. Selain itu, di data berdimensi tinggi, konsep “kemiripan” bisa menjadi kabur (*curse of dimensionality* membuat hampir setiap titik saling berjauhan), sehingga adakalanya perlu dilakukan seleksi atau reduksi dimensi sebelum clustering. Hasil klusterisasi pun perlu diinterpretasi secara hati-hati – memberikan *label* atau deskripsi yang bermakna untuk tiap kluster membutuhkan pemahaman domain. Misalnya, setelah algoritma mengelompokkan

pelanggan menjadi 5 klaster berdasarkan pola belanja, analis harus menggali apa ciri khas setiap klaster (usia muda vs tua, pembelian produk premium vs standar, dsb.) agar klaster tersebut actionable secara bisnis. Terakhir, clustering bisa sensitif terhadap *outlier*; data pencilan dapat memengaruhi penentuan pusat klaster secara signifikan. Oleh sebab itu, prapemrosesan seperti menghapus outlier ekstrem atau menggunakan algoritma yang robust perlu dilakukan. Tren riset terkini di bidang clustering mencakup pengembangan metode *clustering* baru yang lebih adaptif dan mampu menangani dataset besar secara real-time, termasuk pendekatan berbasis pembelajaran mendalam dan *evolutionary algorithms* (Zhou *et al.*, 2021⁵⁶⁵⁷). Inovasi-inovasi ini diharapkan dapat mengatasi keterbatasan algoritma klasik serta menghasilkan pengelompokan yang lebih akurat dan stabil. Secara keseluruhan, clustering merupakan teknik esensial dalam BI untuk memahami struktur data. Dengan mengelompokkan entitas bisnis ke dalam klaster yang bermakna, perusahaan dapat memperoleh *insight* mendalam tentang pola tersembunyi dan kemudian menyesuaikan strategi bisnis sesuai karakteristik tiap kelompok tersebut, yang pada akhirnya meningkatkan efektivitas keputusan dan kinerja bisnis secara keseluruhan.

Daftar Pustaka

- Ahmed, N. K., Atiya, A. F., Gayar, N. E., & El-Shishiny, H. (2020). An empirical comparison of machine learning models for time series forecasting. *Econometric Reviews*, 39(6), 592–625. <https://doi.org/10.1080/07474938.2020.1727710>
- Cambria, E., Li, Y., Xing, F. Z., Poria, S., & Kwok, K. (2022). SenticNet 7: A commonsense-based neuro-symbolic AI framework for explainable sentiment analysis. In *Proceedings of the 31st International Joint Conference on Artificial Intelligence (IJCAI)* (pp. 3753–3759). <https://doi.org/10.24963/ijcai.2022/521>
- Chen, H., Chiang, R. H. L., & Storey, V. C. (2021). Business intelligence and analytics: From big data to big impact. *MIS Quarterly*, 45(3), 789–801. <https://doi.org/10.25300/MISQ/2021/15048>
- Delen, D., & Ram, S. (2018). Research challenges and opportunities in business analytics. *Journal of Business Analytics*, 1(1), 2–12. <https://doi.org/10.1080/2573234X.2018.1507324>
- Gupta, M., & George, J. F. (2021). Toward the development of a big data analytics capability. *Information & Management*, 58(3), 103434. <https://doi.org/10.1016/j.im.2020.103434>
- Gürçan, F., Özkan, S., & Aral, T. (2023). Business Intelligence Strategies, Best Practices, and Latest Trends: A Bibliometric Analysis. *Sustainability*, 15(1), 334. <https://doi.org/10.3390/su15010334>
- Hmoud, H., Alshurideh, M., & Al Kurdi, B. (2023). Factors influencing business intelligence adoption in higher education institutions. *International Journal of Information Management*, 69, 102562. <https://doi.org/10.1016/j.ijinfomgt.2022.102562>
- Hutto, C., & Gilbert, E. (2021). VADER: A parsimonious rule-based model for sentiment analysis of social media text. In *Proceedings of the International Conference on Weblogs and Social Media (ICWSM)* (pp. 216–225).
- Jannach, D., Lerche, L., Jugovac, M., & Gedikli, F. (2021). What recommenders recommend – An analysis of recommendation biases and possible countermeasures. *User Modeling and User-Adapted Interaction*, 31(3), 441–489. <https://doi.org/10.1007/s11257-021-09280-5>

- Kaur, P., & Kautish, S. (2021). Natural language processing applications in business intelligence: A review. *Journal of Business Analytics*, 4(3), 257–274. <https://doi.org/10.1080/2573234X.2021.1910897>
- Kotu, V., & Deshpande, B. (2019). *Predictive analytics and data mining: Concepts and practice with RapidMiner* (2nd ed.). Morgan Kaufmann.
- Liu, B. (2020). *Sentiment analysis: Mining opinions, sentiments, and emotions*. Cambridge University Press.
- Manning, C. D., & Jurafsky, D. (2020). *Speech and language processing* (3rd ed. draft). Stanford University. <https://web.stanford.edu/~jurafsky/slp3/>
- Matias, R., & Piedade, M. B. (2024). A Framework for Self-Service Business Intelligence. In *Proceedings of the 16th International Conference on Information Management and Big Data (SIMBig 2024)*. SCITEPRESS. <https://doi.org/10.5220/0012345600003644>
- Medhat, W., Hassan, A., & Korashy, H. (2021). Sentiment analysis algorithms and applications: A survey. *Ain Shams Engineering Journal*, 12(4), 3773–3785. <https://doi.org/10.1016/j.asej.2020.09.006>
- Mishra, D., Gunasekaran, A., Papadopoulos, T., & Hazen, B. T. (2020). Green supply chain performance measures: A review and bibliometric analysis. *Sustainable Production and Consumption*, 23, 199–210. <https://doi.org/10.1016/j.spc.2020.05.006>
- Ragazou, K., Passas, I., Garefalakis, A., & Zopounidis, C. (2023). Business intelligence model empowering SMEs to make better decisions and enhance their competitive advantage. *Discover Analytics*, 1, Article 2. <https://doi.org/10.1007/s44257-022-00002-3>
- Ricci, F., Rokach, L., & Shapira, B. (2022). *Recommender systems handbook* (3rd ed.). Springer. <https://doi.org/10.1007/978-1-0716-2197-4>
- Sharda, R., Delen, D., & Turban, E. (2020). *Business intelligence, analytics, and data science: A managerial perspective* (4th ed.). Pearson.
- Shmueli, G., Bruce, P. C., Yahav, I., Patel, N. R., & Lichtendahl Jr, K. C. (2020). *Data mining for business analytics: Concepts, techniques, and applications in Python*. Wiley.
- Waller, M. A., & Fawcett, S. E. (2019). Data science, predictive analytics, and big data: A revolution that will transform supply chain design and management. *Journal of Business Logistics*, 40(2), 77–84. <https://doi.org/10.1111/jbl.12201>
- Zhang, S., Yao, L., Sun, A., & Tay, Y. (2019). Deep learning based recommender system: A survey and new perspectives. *ACM Computing Surveys*, 52(1), 1–38. <https://doi.org/10.1145/3285029>
- Zhou, Y., Wilkinson, D., Schreiber, R., & Pan, R. (2020). Large-scale parallel collaborative filtering for the Netflix Prize. In *Algorithmic aspects in information and management* (pp. 337–348). Springer. https://doi.org/10.1007/978-3-030-51831-6_28

Zhou, Z. H., Chen, S. F., & Dai, H. (2021). Evolutionary learning: Advances in theories and algorithms. *Artificial Intelligence Review*, 54(2), 981–1027. <https://doi.org/10.1007/s10462-020-09868-3>

1 4 13 Business intelligence model empowering SMEs to make better decisions and enhance their competitive advantage | Discover Analytics

<https://link.springer.com/article/10.1007/s44257-022-00002-3>

2 3 (PDF) Research challenges and opportunities in business analytics

https://www.researchgate.net/publication/327202967_Research_challenges_and_opportunities_in_business_analytics

5 6 7 8 9 10 11 12 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35
36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 56 57 5220311119_Jaka

Anandaru_RANGKUMAN BI.pdf

<file:///file-9BLtAmQAoKuaohwgBXrKBB>

53 54 Microsoft Word - 51-Ceska Petr Havel-preuredjen

https://www.temjournal.com/content/113/TEMJournalAugust2022_1399_1405.pdf

55 A comprehensive review of visualization methods for association ...

<https://www.sciencedirect.com/science/article/abs/pii/S0957417423014033>